



DEPARTAMENTO
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

Trabajo Práctico II: Bases de datos NoSql

Bases de Datos
Segundo Cuatrimestre de 2015

Integrante	LU	Correo electrónico
Raul Benitti	592/08	raulbenitti@gmail.com
Damian Castro	326/11	ltdicai@gmail.com
Leandro Matayoshi	79/11	leandro.matayoshi@gmail.com
Javier San Miguel	786/10	javiersm00@gmail.com



1. Modelo

Como regla general, el modelo está pensado en función de las consultas que se desea responder. Para ello, utilizamos la desnormalización y la redundancia de datos como mecanismos válidos para poder resolver las consultas rápida y eficientemente.

Esto produce como consecuencia la posibilidad de producir inconsistencias en la base de datos. Por lo tanto, es responsabilidad del programador realizar los chequeos correspondientes a la hora de insertar, modificar o eliminar datos.

1.1. Empleados que atendieron clientes mayores de edad

Para poder satisfacer los requerimientos de la query, mantenemos en la colección *Empleados* una lista de clientes, que contiene los identificadores de cada uno. Para esto utilizamos 2 arreglos, diferenciando entre clientes mayores y menores de edad.

```
1  {
2    "_id" : ObjectId("5622bf41228da935bd5e0a6a"),
3    "nroLegajo" : 234,
4    "nombre" : "Pepito Suarez",
5    "clientes_mayores" : [
6      {
7        "_id" : ObjectId("5622c1d3228da935bd5e0a6b"),
8        "fecha" : ISODate("2015-10-01T00:00:00Z")
9      }
10   ],
11   "clientes_menores" : [ ],
12   "sectores" : [
13     {
14       "sector" : "Comestibles",
15       "tarea" : "Gerente"
16     },
17     {
18       "sector" : "Indumentaria deportiva",
19       "tarea" : "Supervisor"
20     }
21   ]
22 }
```

Listing 1: Ejemplo Empleado

Consulta: `db.empleados.find({"clientes_mayores": {$exists: true, $not: {$size: 0}}})`

1.2. Artículos más vendidos

Agregamos en un atributo *cant_unidades_vendidas* que nos permite encontrar el máximo muy eficientemente. No mantenemos información acerca de los clientes que compraron ese producto, ya que esta última colección es la encargada de llevar ese registro.

Consulta:

En primer lugar, realizamos una agregación con un único grupo: *_id: null*, mediante la cual encontramos el máximo entre todas las cantidades vendidas. Luego realizamos una nueva query, filtrando por igualdad sobre dicha máxima cantidad obtenida.

```
1 {
2   "_id" : ObjectId("5622d234228da935bd5e0a6f"),
3   "codBarras" : 342391,
4   "nombre" : "Pro Speed Z-7",
5   "sector" : "Calzado",
6   "cant_unidades_vendidas" : 0
7 }
```

Listing 2: Ejemplo Artículo

1. `max_cant_unidades_vendidas = (db.articulos.aggregate([{$group: {_id: null, max: {$max: "$cant_unidades_vendidas"}}}])).next().max`
2. `db.articulos.find({"cant_unidades_vendidas": max_cant_unidades_vendidas})`

1.3. Sectores donde trabajan exactamente 3 empleados

La colección *Sectores* mantiene una lista con los ids de los empleados que trabajan en él.

```
1 {
2   "_id" : ObjectId("5622df91228da935bd5e0a75"),
3   "codSector" : "Comestibles",
4   "empleados" : {
5     "lista" : [ ObjectId("5622bf41228da935bd5e0a6a") ]
6   }
7 }
```

Listing 3: Ejemplo Sector

Consulta: `db.sectores.find({"empleados.lista": {$size: 3}})`

1.4. Empleado que trabaja en más sectores

Consulta:

La consulta es análoga a “artículos más vendidos”. En primera instancia encontramos el máximo, y luego seleccionamos aquellos documentos con valor igual a dicho máximo.

1. `var max = db.empleados.aggregate([{$group: {_id: null, max: {$max: {$size: "$sectores"}}}])).next().max`
2. `db.empleados.find({sectores: {$size: max}})`

1.5. Ranking de los clientes con mayor cantidad de compras (total de unidades)

El cliente mantiene una lista con los artículos que compra. Cuando el cliente compra una cantidad determinada de un producto, se agrega una nueva entrada al final de *lista*, sumando al valor de total

la cantidad de unidades compradas. Este campo admite repetidos sobre *id*, lo cual agrega eficiencia a la hora de insertar una nueva compra.

```
1  {
2    "_id" : ObjectId("5622c1d3228da935bd5e0a6b"),
3    "dni" : 28012849,
4    "nombre" : "Julio Jericho",
5    "edad" : 23,
6    "articulos" : {
7      "total" : 4,
8      "lista" : [ {"id": ObjectId("ff20ef41228da935bd5583bd"), "cantidad": 3},
9                  {"id": ObjectId("4729bce098bbdde98100acc"), "cantidad": 1}
10     ]
11   }
12 }
```

Listing 4: Ejemplo Cliente

Consulta:

El ranking está determinado por un ordenamiento descendente sobre el total de compras realizadas por cada cliente.

```
db.clientes.aggregate([{$sort : { "articulos.total": -1 } } ])
```

1.6. Cantidad de compras realizadas por clientes de la misma edad

Consulta:

Agrupamos los documentos por edad proyectando el total de artículos comprados. Finalmente realizamos una agregación sobre cada grupo, sumando *total*.

```
db.clientes.aggregate([{$project: { "art_total": "$articulos.total", "edad": 1}}, {$group: {_id: "$edad",
total: { $sum: "$art_total" }}}])
```

2. MapReduce

2.1. Cantidad de disposiciones de tipo resoluciones realizadas en Abril del 2013

Por cada disposición, si cumple con las restricciones emitimos como clave: “Resoluciones”, y 1 como valor. El reduce consiste simplemente en la suma de todos los valores.

```
var m = function(){
  var date = convertDate(this.FechaDisposicion);
  if(date){
    var month = date.getMonth();
    if (month == 3 && this.Tipo == "Resoluciones"){
      emit(this.Tipo, 1);
    }
  }
}

var r = function(key, values) {
  return Array.sum(values)
}

printjson(db.disposiciones.mapReduce(m,r,{out: {inline: 1},
  scope: {convertDate: convertDate}}));
```

2.2. Cantidad de disposiciones por tipo definido

Este caso consiste en un agrupamiento por “Tipo” con la suma de la cantidad de documentos como valor. Por lo tanto, la clave en este caso es el tipo de la disposición. Al igual que en el caso anterior, se emite 1 como valor por cada documento y al reducir se suman todos los valores.

```
var m = function(){
  if (this.Tipo != ""){
    emit(this["Tipo"], 1);
  }
}

var r = function(key, values) {
  return Array.sum(values);
}

printjson(db.disposiciones.mapReduce(m,r,{out: {inline: 1}}));
```

2.3. Fecha más citada para todos los informes

Utilizamos la función `convertDate` para transformar las distintas fechas a un formato común. Las fechas se presentan como day-month-year, day/month/year o en formato iso: 2015-11-21T01:51:17Z.

Las claves son las fechas normalizadas, y emitimos 1 como valor tanto por la *FechaBOJA* como por la *FechaDisposicion*.

```
var m = function(){
  var fecha_boja = convertDate(this.FechaBOJA);
  var fecha_disp = convertDate(this.FechaDisposicion);
  if (fecha_boja){
    emit(fecha_boja, 1);
  }
  if(fecha_disp){
    emit(fecha_disp, 1);
  }
}
```

```
var r = function(key, values) {
    return Array.sum(values);
}

var res = db.disposiciones.mapReduce(m,r,{out: {inline: 1},
                                     scope: {convertDate: convertDate}})

printjson(res);

//Find max
var max = null;
for(var idx = 0; idx < res.results.length; ++idx){
    var item = res.results[idx];
    if(max){
        if (Math.max(max.value, item.value) != max.value) max = item;
    }
    else{
        max = item;
    }
}

printjson(max);
```

2.4. Devolver la mayor cantidad de páginas utilizadas por cada tipo de disposición

La consulta consiste en un agrupamiento sobre tipo de disposición con agregación sobre el máximo de las páginas utilizadas.

Por lo tanto emitimos el tipo de documento como clave y la cantidad de páginas utilizadas como valor. El reduce encuentra el máximo sobre la lista de valores.

```
var m = function(){
    var pagina_inicial = this["PaginaInicial"],
        pagina_final = this["PaginaFinal"];
    emit(this["Tipo"], pagina_final - pagina_inicial)
}

var r = function(key, values){
    var max = 0;
    // Calculo del maximo
    for(var i = 0; i < values.length; ++i){
        if (values[i] > max){
            max = values[i];
        }
    }
    return max;
}

var res = db.disposiciones.mapReduce(m, r, {out: {inline: 1}})
printjson(res);
```

2.5. Función para convertir las fechas

```
function convertDate(str){
    if(str == "") return null;
    if(/^\\d{4}-\\d{2}-\\d{2}T\\d{2}:\\d{2}:\\d{2}Z?$/ .test(str)){
        return new Date(str.replace(/^00/, "20"));
    }
    else if(/^\\d{2}[-\\/\\d{2}[-\\/\\d{4}]/ .test(str)){
        var parts = str.split(/[-\\/]/);
        var aux = parts[0];
        parts[0] = parts[2];
        parts[2] = aux;
        return new Date(parts.join("-"));
    }
}
```

```
}  
else{  
    return null;  
}  
}
```

3. Sharding

3.1. Partición basada en rango




Figura 1: 2 Shards utilizando partición de keys por rango




Figura 2: 3 Shards utilizando partición de keys por rango

3.2. Partición basada en hash




Figura 3: 2 Shards utilizando partición de keys basada en hash




Figura 4: 3 Shards utilizando partición de keys basada en hash